## Yerel LLM Güvenlik Raporlama

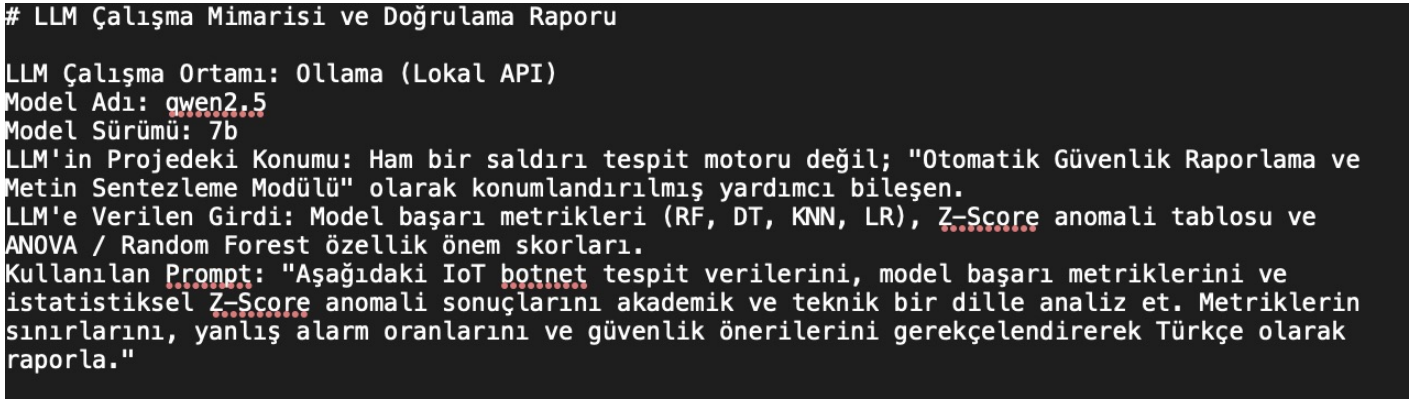
Çalışmamızda, makine öğrenmesi ve istatistiksel analiz sonuçlarını açıklayıcı bir güvenlik raporuna dönüştürmek için Ollama üzerinden **Qwen2.5:7b** modeli kullanılmıştır. Yerel LLM, hesaplanan performans metriklerini, özellik analizlerini ve anomali sonuçlarını yorumlayarak güvenlik değerlendirmesi ve öneriler üretmektedir.

## Yerel Modelin Çalıştırılması ve Python Bağlantısı

Ollama kurulduktan sonra Qwen2.5:7b modeli terminal üzerinden indirilip çalıştırılmıştır:
Python uygulaması, requests kütüphanesiyle Ollama'nın http://localhost:11434/api/generate adresine istek göndermektedir. İstekte model adı, prompt ve analiz bulguları iletilmekte; dönen yanıt güvenlik raporuna aktarılmaktadır.

## LLM Çalışma Mimarisi

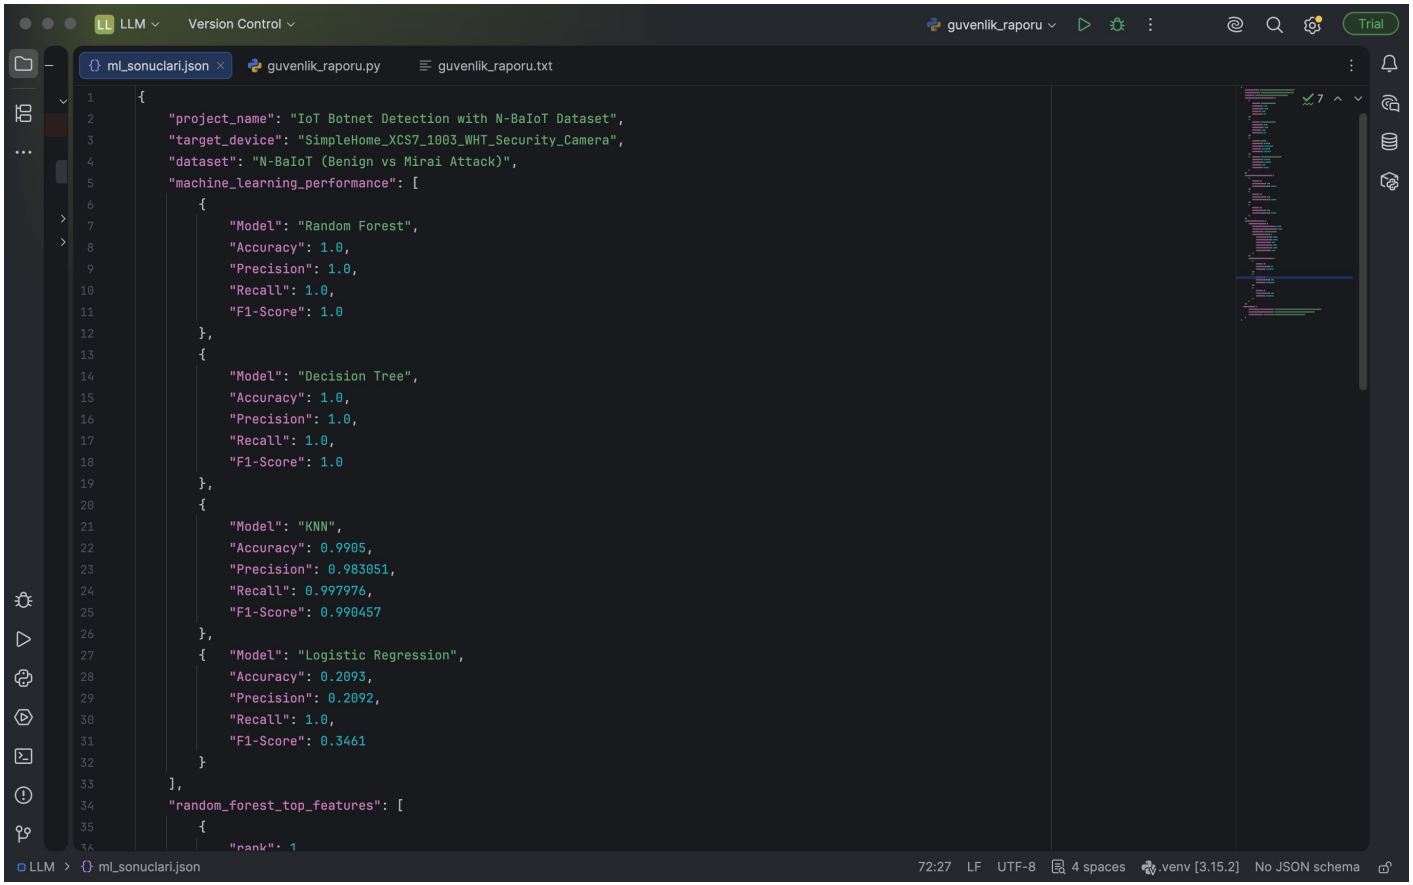
- Çalışma ortamı: Ollama yerel API
- Kullanılan model: Qwen2.5:7b
- Projedeki rolü: Analiz sonuçlarını yorumlayan ve güvenlik önerileri üreten yardımcı raporlama bileşeni
- Girdiler: Model performans metrikleri, Z-Score sonuçları, Random Forest özellik önemleri ve ANOVA F skorları
- Prompt özeti: Bulguları Türkçe yorumlayarak metriklerin sınırlarını, yanlış alarmları ve gerekçeli güvenlik önerilerini açıklamak



```
# LLM Çalışma Mimarisi ve Doğrulama Raporu

LLM Çalışma Ortamı: Ollama (Lokal API)
Model Adı: qwen2.5
Model Sürümü: 7b
LLM'in Projedeki Konumu: Ham bir saldırı tespit motoru değil; "Otomatik Güvenlik Raporlama ve
Metin Sentezleme Modülü" olarak konumlandırılmış yardımcı bileşen.
LLM'e Verilen Girdi: Model başarı metrikleri (RF, DT, KNN, LR), Z-Score anomali tablosu ve
ANOVA / Random Forest özellik önem skorları.
Kullanılan Prompt: "Aşağıdaki IoT botnet tespit verilerini, model başarı metriklerini ve
istatistiksel Z-Score anomali sonuçlarını akademik ve teknik bir dille analiz et. Metriklerin
sınırlarını, yanlış alarm oranlarını ve güvenlik önerilerini gerekçelendirerek Türkçe olarak
raporla."
```

# LLM’ye Verilen Girdiler




Yerel LLM’nin değerlendirmede kullanacağı sonuçlar ml_sonuclari.json dosyasında bir araya getirilmiştir.

Model performansları: Random Forest, Decision Tree, KNN ve ek Logistic Regression deneyine ait Accuracy, Precision, Recall ve F1 skorları.

Özellik analizleri: Random Forest özellik önemleri ve ANOVA F skorları; öne çıkan sütun indeksleri.

Anomali sonuçları: Z-Score eşiği, incelenen ve işaretlenen kayıt sayıları; doğru yakalanan saldırılar, yanlış alarmlar, kaçırılan saldırılar ve doğru normal kayıtlar.

Deney bilgileri: Kullanılan kamera, veri kümesi, eğitim-test ayrım oranı ve test yöntemi.

Bu aşamada LLM’ye ham trafik kayıtları değil, analizlerden elde edilen özet bulgular aktarılmıştır.

## 1.Kullanılan Sistem İstemi (Prompt)

Yerel LLM’ye verilen sistem istemiyle raporun kapsamı, yorumlama kuralları ve çıktı biçimi tanımlanmıştır.

Görev: Makine öğrenmesi ve istatistiksel analiz sonuçlarını Türkçe yorumlamak.

Model karşılaştırması: Decision Tree, Random Forest ve KNN’yi dört metrikle karşılaştırmak; Logistic Regression ek deneyini ayrı değerlendirmek.

Özellik analizi: Random Forest ve ANOVA sonuçlarını ayrı yorumlamak.

Bilgi sınırı: Verilmeyen nedenleri veya özelliklerin trafik anlamlarını tahmin etmemek.

```
def yorumlari_uret(bulgular):  1 usage
    sistem = """
        Türkçe, akıcı ve akademik bir güvenlik değerlendirmesi yaz.
        Görevin, verilen makine öğrenmesi ve istatistiksel analiz sonuçlarını
        yorumlamaktır. Yeni saldırı sınıflandırması yapma.
```

```
TEHDİT ALANI:
Decision Tree, Random Forest ve KNN'nin raporlanan doğruluk,
kesinlik, duyarlılık ve F1 değerlerini sayısal olarak karşılaştır.
Her metriği ayrı değerlendir. Dört metriği eşit olan modellerin
raporlanan ölçümlerde eşit olduğunu açıkça belirt.

Logistic Regression gibi ek deneyleri ayrı değerlendir.
Her modelin dört metriğini kendi tablo satırından ayrı ayrı oku.
Bir modelin bazı metriklerinin düşük olmasını bütün metriklerinin
düşük olduğu şeklinde genelleme.
Eşitlik belirtirken hangi modellerin hangi metrikte eşit olduğunu yaz.
Decision Tree, Random Forest ve KNN'nin hiçbirini yorumdan çıkarma.
Ek deneyin aynı test koşullarında yapıldığı doğrulanmamışsa,
doğrudan üstünlük sıralamasına katılmasının sınırlı olduğunu belirt.
Bu belirsizliği bütün proje modellerine genelleme.

Model puanlarından veri temizliği veya sınıf dengesi hakkında
sonuç çıkarma. Başarının ya da başarısızlığın nedeni kaynakta
gösterilmemişse neden açıklaması ekleme.
Sınıf dağılımı verilmişse yalnızca dağılımı aktar; bunu model
başarısının nedeni olarak sunma.


Random Forest ve ANOVA analizlerini ayrı ayrı açıkla.
Her yöntemde öne çıkan özellikleri, verilen indeksleri ve skorlarıyla
belirt. Adlar verilmişse kullan; verilmemişse indekslerle tanımla.
"Bu analizde en yüksek puanları alan özellikler" ifadesini kullan.
Bu özelliklerin vazgeçilmez olduğunu iddia etme.
Random Forest önem puanları ile ANOVA F skorlarını doğrudan karşılaştırma.
Bu sonuçlardan saldırının nedenini veya etkinin yönünü çıkarma.
Özellik açıklamaları yoksa trafik anlamlarını tahmin etme.
```

## 2. Güvenlik Önerileri İçin Prompt Kuralları

```
ANOMALİ ALANI:

Kesinliği açıklarken uyarılar içindeki gerçek saldırı payını belirt.
Duyarlılığı açıklarken gerçek saldırılar içindeki yakalanan payı belirt.
Yanlış alarm oranını normal kayıtlar üzerinden açıkla.
Kayıt adetlerine yüzde işareti ekleme.
Yüksek veya düşük değerlendirmelerinin hangi sayıya dayandığını belirt.

Z-Score deneyini makine öğrenmesi deneyinden ayrı değerlendir.
Toplam incelenen kayıt, anomali olarak işaretlenen kayıt,
doğru yakalanan saldırı, yanlış alarm ve kaçırılan saldırı sayılarını
kaynakta verildiği şekilde kullan.

Anomali uyarılarının ne kadarının saldırı olduğunu, verilen kesinlik
değeri ve doğru yakalanan saldırı sayısıyla açıkla.
Gerçek saldırıların ne kadarının yakalandığını verilen duyarlılık
değeriyle, kaçırılan saldırıların büyüklüğünü ise verilen sayıyla açıkla.
Normal kayıtların ne kadarının yanlış alarm ürettiğini verilen
yanlış alarm oranıyla belirt.

Normal kayıtlar üzerinden hesaplanan yanlış alarm oranını,
uyarılar içindeki yanlış alarm payıyla karıştırma.
Verilmemiş oranları tahmin etme.
Anomali sayısını doğrulanmış saldırı sayısı olarak sunma.
Yüksek veya düşük değerlendirmelerini sayılarla gerekçelendir.
Sonuçları incelenen örneklem, eşik ve uygulamayla sınırlandır.
Yazım talimatlarını tekrarlamak yerine bu bulguların anlamını açıkla.
```

```
AKSİYONLAR ALANI:

Kaynak bulgulardan dört gerekçeli güvenlik önerisi üret.
Her öneriyi gözlenen bir sonuç veya eksik bilgiyle ilişkilendir.
Önerileri tek paragrafta ayrı cümlelerle yaz.
Özelliklerin trafik anlamları bilinmiyorsa belirli engelleme kuralları türetme.
Eşik değerlendirmesinde yanlış alarmları ve kaçırılan saldırıları birlikte ele al.
Eşik veya model ayarları için doğrulama verisi kullanılmasını belirt;
son test kümesini ayarlama amacıyla kullanmayı önerme.
Yeni sayısal eşik veya başarı garantisi verme.
Mevcut deney dışındaki geçerliliği ve müdahale öncesi doğrulamayı değerlendir.
Yapılmamış işlemleri yapılmış gibi anlatma.
"""
```

## Raporun Oluşturulması

Python uygulaması, ml_sonuclari.json dosyasını okuyarak sayısal tabloları ve anomali oranlarını hazırlamaktadır. Bu bulgular, prompt ile birlikte Ollama'nın yerel API'sine gönderilmektedir.
Qwen2.5:7b, sonuçları Türkçe yorumlayarak tehdit değerlendirmesi, anomali özeti ve güvenlik önerileri üretmektedir. JSON biçiminde alınan yanıt, sayısal tablolarla birleştirilerek guvenlik_raporu.txt dosyasına kaydedilmektedir.

```
yanit = requests.post(
    OLLAMA_URL,
    json={
        "model": MODEL, "system": sistem,
        "prompt": "Kaynak bulgular:\n" + json.dumps(bulgular, ensure_ascii=False)
                + "\nYanıt şeması:\n" + json.dumps(RAPOR_SEMASI, ensure_ascii=False),
        "format": RAPOR_SEMASI, "think": False, "stream": False,
        "options": {"temperature": 0, "num_predict": 2200, "num_ctx": 8192},
    }
)
yanit.raise_for_status()
govde = yanit.json()

print("\n--- OLLAMA API YANITI ---")
print("API adresi:", OLLAMA_URL)
print("Yanıttaki model:", govde.get("model"))
print("Oluşturulma zamanı:", govde.get("created_at"))
print("LLM'nin ham yorumu:")
print(govde.get("response"))
print("--- YANIT SONU ---\n")

metin = govde.get("response")
yorumlar = json.loads(metin)
return yorumlar
```

## Ollama API Yanıtı

Python uygulaması, analiz bulgularını ve promptu http://localhost:11434/api/generate adresine göndermektedir.

Ollama'dan dönen yanıtta model adı, oluşturulma zamanı ve üretilen değerlendirme metni bulunmaktadır.

API'den alınan yorumlar, sayısal tablolarla birleştirilerek güvenlik raporuna aktarılmaktadır.



## Güvenlik Raporu

Oluşturulan guvenlik_raporu.txt dosyası dört bölüm içermektedir:

- LLM Çalışma Mimarisi ve Doğrulama Raporu: Çalışma ortamı, model, girdiler ve prompt bilgileri.
- Tehdit Durum Değerlendirmesi: Model performans tabloları, özellik analizi sonuçları ve yerel LLM'nin değerlendirmeleri.

```
# Tehdit Durum Değerlendirmesi

Proje: IoT Botnet Detection with N-BaIoT Dataset

Cihaz türü: SimpleHome XCS7 1003 WHT Security Camera

Veri kümesi: N-BaIoT (Benign vs Mirai Attack)

Ek deney bilgileri: test edilen kayıt sayısı: 4.000 adet kayıt (Toplam 20.000 veri üzerinden); eğitim test ayırma oranı:
%80 Eğitim – %20 Test (train test split); test yöntemi: Hold-out (Rastgele Ayrım – random_state=42)

**Model sonuçları**

| Model | Kapsam | Doğruluk | Kesinlik | Duyarlılık | F1 skoru |
| --- | --- | --- | --- | --- | --- |
| Decision Tree | Proje modeli | %100,0000 | %100,0000 | %100,0000 | %100,0000 |
| Random Forest | Proje modeli | %100,0000 | %100,0000 | %100,0000 | %100,0000 |
| KNN | Proje modeli | %99,0500 | %98,3051 | %99,7976 | %99,0457 |
| Logistic Regression | Ek deney | %20,9300 | %20,9200 | %100,0000 | %34,6100 |

JSON'daki dört metriği aynı olan modeller: Random Forest, Decision Tree.

**Random Forest özellik önemleri**

| Sütun numarası | Özellik adı | Önem skoru |
| --- | --- | --- |
| 14 | Özellik adı verilmedi | 0,1141 |
| 27 | Özellik adı verilmedi | 0,0908 |
| 28 | Özellik adı verilmedi | 0,0801 |

**ANOVA özellik analizi**

| Sütun numarası | Özellik adı | F skoru |
| --- | --- | --- |
| 9 | Özellik adı verilmedi | 363.942,30 |
| 24 | Özellik adı verilmedi | 363.942,28 |
| 29 | Özellik adı verilmedi | 355.541,30 |

Random Forest önemleri modelin özelliklere verdiği göreli önemi gösterir; saldırı olasılığı veya başarı oranı değildir.
ANOVA F skoru gruplar arası değişkenliği grup içi değişkenliğe göre değerlendirir; yüzde değildir. P değerleri ve test
varsayımları verilmediğinden kesin anlamlılık iddiası kurulmaz. Özellik adı sağlanmayan sütunların trafik anlamı tahmin
edilmez.
```

```
**Yerel LLM değerlendirmesi:**

Proje, IoT kamera ağ trafiğinde normal kayıtlarla botnet saldırıları ayırt etmeye odaklanmaktadır. Bu amaçla, Decision
Tree, Random Forest, KNN ve Logistic Regression modelleri kullanılmıştır. Model sonuçları, her modelin dört metriği
(Doğruluk, Kesinlik, Duyarlılık, F1 Skoru) karşılaştırılmıştır. Decision Tree ve Random Forest modelleri, her metriği
%100 puanla başarıyla sınıflandırmışlardır, ancak KNN modeli %99.0500 doğruluk puanıyla en düşük performans göstermiştir.
Logistic Regression, ek deneyde %20.9300 doğruluk puanıyla en düşük performans göstermiştir. Bu sonuçlar, modelin
sınıflandırma performansını ve potansiyel yanlış alarm oranlarını belirleyen kritik faktörleri vurgulamaktadır.
```

## Güvenlik Raporu

- Tespit Edilen Anomali Özeti: Z-Score ile işaretlenen kayıtlar, yakalanan saldırılar, yanlış alarmlar ve kaçırılan saldırılara ilişkin bulgular.

```
# Tespit Edilen Anomali Özeti

| Ölçüt | Değer |
| --- | --- |
| İncelenen kayıt | 6.000 |
| Anomali eşiği | abs(z) > 3 |
| Anomali işaretlenen kayıt | 461 |
| Anomali oranı | %7,68 |
| Etiketi normal olan kayıt | 3.000 |
| Etiketi saldırı olan kayıt | 3.000 |
| Doğru yakalanan saldırı (TP) | 57 |
| Yanlış alarm (FP) | 404 |
| Kaçırılan saldırı (FN) | 2.943 |
| Doğru normal (TN) | 2.596 |
| Anomali uyarılarının kesinliği | %12,36 |
| Saldırı yakalama oranı | %1,90 |
| Yanlış alarm oranı | %13,47 |

Bu değerlendirme ML model karşılaştırmasından ayrıdır. Z-Score uyarısı tek başına doğrulanmış saldırı değildir.

Oranlar verilen sayılardan hesaplandı; ham trafik kayıtları yeniden işlenmedi.

**Yerel LLM değerlendirmesi:**

Z-Score analizi, 6.000 incelenen kayıtlardan 461 anomali olarak işaretlenmiş, bu oran %7.68'dir. Saldırılar etiketlenen
3.000 normal kayıttan 57 doğru yakalanan, 404 yanlış alarm ve 2.943 kaçırılan saldırı olarak belirlenmiştir. Anomali
uyarılarının kesinliği %12.36, saldırı yakalama oranı %1.90 ve yanlış alarm oranı %13.47 olarak belirlenmiştir. Bu
sonuçlar, Z-Score analizinin sadece bir uyarı mekanizması olduğunu ve doğrulanmış saldırılar için tam bir güvenilirlik
sağlayamadığını göstermektedir.
```

## Güvenlik Raporu

- Önerilen Güvenlik Aksiyonları: Model parametrelerinin incelenmesi, anomali eşiğinin değerlendirilmesi ve ek veriyle test yapılmasına yönelik LLM önerileri.

```
# Önerilen Güvenlik Aksiyonları

Bulunduğumuz durumda, aşağıdaki güvenlik önerileri sunulabilir:
1. Model performansını ve sınıflandırma doğruluğunu artırmak için, KNN modelinin performansını iyileştirmek için
parametre ayarlarını gözden geçirmek önemlidir.
2. Z-Score analizinin sınıflandırma performansını artırma amacıyla, anomali eşiğinin optimizasyonu ve daha hassas bir
uyarı sistemi geliştirilmesi gerekmektedir.
3. Logistic Regression modelinin düşük performansı nedenini incelemek ve potansiyel olarak daha iyi bir sınıflandırma
modeli seçmek veya mevcut modelin performansını iyileştirmek için yeni özellikler eklemek önemlidir.+
4. Modelin performansını ve doğruluğunu artırmak için, daha büyük ve daha dengeli bir veri kümesi kullanmak ve veri
temizliği süreçlerini optimize etmek önemlidir.
```

## Çıktı Kontrolü ve Sınırlılıklar

Yerel LLM'nin ürettiği rapor, kaynak tablolarla karşılaştırılmıştır.
Sayısal değerlerin çoğu doğru aktarılmış; ancak bazı yorumlarda hata ve eksiklikler belirlenmiştir.

| Belirlenen sorun | Doğru değerlendirme |
|---|---|
| Z-Score yorumunda normal ve saldırı kayıtları karıştırılmıştır. | 57 yakalanan ve 2.943 kaçırılan kayıt saldırı sınıfına; 404 yanlış alarm normal sınıfa aittir. |
| KNN ve LR için "en düşük performans" ifadesinin kapsamı belirsizdir. | KNN, ana üç model arasında değerlendirilmelidir. LR'nin aynı test koşullarında değerlendirildiği doğrulanmamıştır. |
| Daha dengeli veri ve veri temizliği önerilmiştir. | Bu önerileri gerektiren bir sınıf dengesizliği veya veri kalitesi sorunu kaynak bulgularda gösterilmemiştir. |
| Özellik analizleri LLM yorumunda açıklanmamıştır. | RF ve ANOVA sonuçları ayrı yorumlanmalı; özellik adlarının bulunmaması sınırlılık olarak belirtilmelidir. |